

Módulo 1 — Fundamentos y preparación de datos

Curso de Machine Learning para
estimación de pobreza e inequidad

Bloque teórico — Día 1

Día 1

Banco Mundial - INEC - USFQ

Agenda del bloque

1. ML en estadísticas oficiales
2. Clasificación vs. regresión
3. Fuga de datos (*leakage*)
4. Particiones y *resampling*
5. Preparación de datos: imputación, codificación, escalamiento
6. Regresión lineal y logística como referencia
7. Reproducibilidad y *model cards*
8. Síntesis y Q&A

Al finalizar este módulo el participante será capaz de:

1. Ubicar el ML supervisado dentro del marco inferencial de la estadística oficial.
2. Distinguir clasificación de regresión y justificar la elección.
3. Detectar y prevenir fugas de datos.
4. Diseñar particiones honestas considerando estructura de los datos.
5. Preparar los datos (imputar, codificar, escalar) sin filtrar información.
6. Decidir cuándo un modelo complejo supera al simple.
7. Documentar un modelo con criterios de *model card*.

ML en estadísticas oficiales

¿Qué es aprender? Una intuición primero

En simple: aprender es encontrar una regla que acierte en datos que *aún no hemos visto*, no solo en los que ya tenemos.

Dado $\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n$, buscamos $\hat{f}$ tal que $\hat{f}(x) \approx y$ en datos nuevos.

$$R(f) = \mathbb{E}_{(X,Y) \sim P}[L(Y, f(X))] \quad (\text{lo ideal, desconocido})$$

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) \quad (\text{lo que sí podemos calcular})$$

La brecha entre R y $\hat{R}_n$ es donde vive el oficio.

ML vs. inferencia clásica: dos lógicas, no rivales

	Inferencia clásica	ML supervisado
Objetivo	Parámetros poblacionales	Predicción individual
Aleatoriedad	Diseño muestral	Generalización a P
Incertidumbre	Varianzas analíticas	Remuestreo / ensambles
Validación	Errores estándar	Error fuera de muestra

No son rivales: son objetivos distintos.

- Las encuestas suelen tener diseño complejo (bi-etápico estratificado).
- Los w_i deben usarse en **evaluación** para métricas representativas.
- Pueden incluirse en **entrenamiento** para desensibilizar a estratos.

$$\widehat{\text{Acc}}_w = \frac{\sum_i w_i 1\{y_i = \hat{y}_i\}}{\sum_i w_i}$$

1. Imputación masiva en encuestas
2. *Poverty mapping* (censo + encuesta)
3. *Proxy-means tests* (PMT)
4. Corrección de no-respuesta
5. Edición y deduplicación de registros administrativos
6. Codificación automática de actividad u ocupación

Tres tensiones específicas de la estadística oficial

1. **Trazabilidad metodológica**
(documentación auditable, exigible)
2. **Equidad**
(recall en grupos vulnerables y territorios poco muestreados)
3. **Gobernanza del cambio**
(continuidad de series oficiales, empalme metodológico)

Cualquier modelo ML que alimente un producto oficial debe responder a las tres.

Mensajes clave de la sección

- ML **no reemplaza** la inferencia clásica: la complementa.
- Los factores de expansión son **no-negociables** en evaluación.
- La **cadena de uso institucional** define las decisiones técnicas.

Clasificación vs. regresión

Lo que predecimos define el problema

- Regresión: y numérico (ingreso, gasto, tasa)
- Clasificación: y categórico (pobre/no-pobre, formal/informal)
- Intermedios: ordinal, multilabel, cuantílica

Pregunta clave de diseño: ¿ y es ingreso o estatus de pobreza?

Funciones de pérdida: qué castiga el modelo

Regresión: $L_2 = (y - \hat{y})^2$, $L_1 = |y - \hat{y}|$, Huber, pinball

Clasificación binaria con $\hat{p} = \mathbb{P}(Y = 1 \mid X = x)$:

$$L_{\log} = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$$

Log-pérdida es *proper scoring rule*: su minimizador poblacional es $\eta(x)$.

- **Exactitud** engañosa con desbalance (95 % clasificando todo no-pobre).
- **AUC-PR** $>$ AUC-ROC bajo desbalance fuerte (Saito & Rehmsmeier 2015).
- **Recall** sobre clase pobre suele ser la métrica de política.
- **Brier** y **log-pérdida** miden calibración.

(i) Regresión sobre ingreso + umbral

- Preserva información; recalcula para varios umbrales
- Mejor calibración agregada

(ii) Clasificación directa pobre / no-pobre

- Optimiza la métrica de interés; robusta a outliers de ingreso

Fuga de datos (*leakage*)

Definición

Información que **no estaría disponible en producción** se filtra al entrenamiento o evaluación, inflando artificialmente el desempeño estimado.

Es la causa más común de modelos “demasiado buenos para ser ciertos”.

Fuga del objetivo X_j es función de Y o se midió después

Contaminación (a) preproc sobre todo el dataset; (b) selección con Y del test; (c) tuning leyendo el test

Ejemplo: usar “recibe una transferencia condicionada” como predictor de pobreza. La transferencia se otorga **condicional** al estatus $\Rightarrow$ fuga circular.

Fuga por grupo, temporal y por proxies institucionales

Grupo / conglomerado mismo hogar en train y test

Temporal particiones aleatorias con estructura temporal

Proxies institucionales variables que codifican la decisión a modelar

No es marginal: la magnitud del problema

- Kapoor & Narayanan (2023, *Patterns*): 294 papers en 17 áreas.
- Proporción sustantiva contiene fuga de datos.
- Es sistémico, no anecdótico.
- Riesgo amplificado cuando el modelo alimenta focalización.

Cuatro reglas para prevenir fuga

1. Partir **antes** de cualquier preprocesamiento.
2. Estructura $\rightarrow$ `group_vfold_cv`, `sliding_window`, `spatial_block_cv`.
3. Auditar cada covariable: ¿disponible en producción? ¿medida antes de Y ?
¿codifica el proceso administrativo?
4. Detectada post-hoc: **re-particionar y re-entrenar**.

Particiones y *resampling*

- 70/30 u 80/20 con n grande y clases balanceadas
- Estratificar por Y siempre y por variables sensibles
- `initial_split(strata = ...)` en `rsample`

Validación cruzada de k pliegues: la idea

$$\hat{R}_{CV} = \frac{1}{k} \sum_{j=1}^k \frac{1}{|\mathcal{V}_j|} \sum_{i \in \mathcal{V}_j} L(y_i, \hat{f}^{(-j)}(x_i))$$

- $k \in \{5, 10\}$ estándar (ESL §7.10)
- $k \rightarrow n$ (LOO): sesgo bajo, varianza alta, costo alto
- k pequeño: sesgo mayor (entrenamientos más pequeños)

- Repetir CV con distintas semillas y promediar
- Reduce **varianza** del estimador, no el sesgo
- Útil con n moderado o modelos inestables
- `vfold_cv(repeats = R)` en `rsample`

Bootstrap y observaciones fuera de muestra (OOB)

B muestras con reemplazo de tamaño n :

$$\mathbb{P}(i \notin \mathcal{D}^{*b}) = \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368$$

- $\approx 63,2\%$ de obs. únicas *dentro* de cada muestra
- $\approx 36,8\%$ son **OOB** (out-of-bag)
- OOB se usa internamente en Random Forest (Módulo 2)

Por grupos grupos respetados (hogares, conglomerados)

Temporal `initial_time_split`, rolling-origin

Espacial spatial blocks, buffered CV (Roberts et al. 2017)

Encuestas con diseño bi-etápico estratificado: las métricas no ponderadas **no** son población-representativas.

$$\widehat{\text{Acc}}_w = \frac{\sum_i w_i 1\{y_i = \hat{y}_i\}}{\sum_i w_i}$$

Análogos ponderados para AUC, precision, recall (yardstick acepta case_weights).

Preparación de datos: imputación, codificación, escalamiento

Antes de modelar, casi siempre hay que limpiar y transformar:

1. Rellenar valores faltantes (*imputación*)
2. Convertir categorías en números (*codificación*)
3. Poner las variables en escalas comparables (*escalamiento*)

Regla de oro: aprender estas transformaciones **solo** con el conjunto de entrenamiento, nunca con el de prueba.

Valores faltantes: primero entender por qué faltan

MCAR Faltan al azar, sin relación con nada (raro)

MAR El faltante depende de variables **observadas**

MNAR El faltante depende del **propio valor no observado**

Ejemplo: si los hogares de ingreso alto tienden a no declarar su ingreso, el faltante es MNAR — el más difícil.

Imputación: del método simple al basado en modelo

Simple media / mediana (numéricas), moda (categóricas)

Indicador añadir una variable “estaba faltante” (*flag*)

Por modelo k-NN, árboles, o MICE (imputación múltiple)

La media y los vecinos se calculan SOLO en entrenamiento, luego se aplican al resto.

Los modelos necesitan números; las categorías deben transformarse:

One-hot una columna 0/1 por categoría (sin orden)

Ordinal un entero por nivel (solo si hay orden real)

Cautela codificar usando Y (*target encoding*) puede filtrar el objetivo

Escalamiento: ¿cuándo hace falta?

Normalización llevar a $[0, 1]$: $x' = \frac{x - \text{mín}}{\text{máx} - \text{mín}}$

Estandarización media 0, varianza 1: $x' = \frac{x - \mu}{\sigma}$

Lo necesitan modelos por distancia o gradiente (k-NN, SVM, redes, ridge/lasso).

No lo necesitan los árboles (invariantes a transformaciones monótonas).

Encadenar todo: el pipeline reproducible

- Una *receta* (recipe) declara los pasos en orden
- `prep()` aprende los parámetros **en el train**
- `bake()` los aplica al test **sin recalcular**
- Encapsular en un `workflow` junto con el modelo

Mismo pipeline en entrenamiento, validación y producción $\Rightarrow$ sin fuga, reproducible.

Regresión lineal y logística como referencia

Modelo $Y = X\beta + \varepsilon$:

$$\hat{\beta} = (X^{\top}X)^{-1}X^{\top}y$$

minimizador de $\|y - X\beta\|_2^2$. Gauss-Markov: BLUE bajo supuestos.

- Referencia mínima; sensible a multicolinealidad y outliers

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_2^2 = (X^\top X + \lambda I)^{-1} X^\top y$$

- Ahorra coeficientes sin anular
- Sesgo $\uparrow$, varianza $\downarrow$
- $X^\top X + \lambda I$ siempre invertible para $\lambda > 0$

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1$$

- $\|\beta\|_1$ induce **esparsidad** (selección de variables)
- Coordinate descent / soft-thresholding (Friedman et al. 2010)

Elastic Net: $\lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$ — útil con predictores correlacionados.

$$\mathbb{P}(Y = 1 \mid X = x) = \sigma(x^\top \beta), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\log \frac{\mathbb{P}(Y = 1 \mid X)}{\mathbb{P}(Y = 0 \mid X)} = x^\top \beta$$

MV $\Leftrightarrow$ minimizar log-pérdida. Sin solución cerrada (IRLS o gradiente).

e^{β_j} = OR para un aumento unitario en X_j , ceteris paribus.

- OR > 1: aumenta el odds OR < 1: lo disminuye

Ejemplo: “Piso de tierra”: OR = 3,2 de pobreza extrema → odds 3.2× mayor.

Cuatro razones para empezar por una referencia simple

1. **Interpretable y auditable**
2. **Calibrada por construcción** (consistente para $\eta(x)$ bajo modelo correcto)
3. **Barata** computacionalmente
4. **Defendible** institucionalmente

Regla del 1 %: si un modelo complejo no supera al baseline en ≥ 1 punto de AUC con consistencia, no compensa el costo de gobernanza.

Limitaciones del modelo lineal

- Asume linealidad (o transformaciones manuales)
- No captura interacciones sin ingeniería explícita
- Ridge/lasso requieren escalamiento
- Sensible a especificación funcional

Reproducibilidad y *model cards*

Cuatro niveles de reproducibilidad

1. **Repetible** — mismo equipo, mismo entorno
2. **Reproducible** — otro equipo, mismo código y datos
3. **Replicable** — otros datos del mismo proceso generador
4. **Generalizable** — el hallazgo se sostiene en otras condiciones

- Control de versiones (Git) de código y configuración
- Gestión de dependencias: `renv`
- Semillas fijas, documentadas
- Pipelines encapsulados: `recipe` + `workflow`
- Datos versionados o snapshots fechados
- Logs de entrenamiento; reportes ejecutables (Quarto)

Documento de 1–2 pp. por modelo desplegado. **Nueve secciones:**

1. Detalles
2. Uso previsto
3. Factores relevantes
4. Métricas (desagregadas por subgrupos)
5. Datos de evaluación
6. Datos de entrenamiento
7. Análisis cuantitativo
8. Ética
9. Advertencias

Análogo al *model card*, pero para *datos*:

- Motivación Composición Recolección
- Preprocesamiento Usos previstos
- Distribución y mantenimiento

- Template institucional: **model card + datasheet**
- Exigible para todo modelo que alimente productos publicables o focalización
- Versión pública resumida + versión técnica completa

Síntesis y Q&A

- ML es predicción individual, no inferencia poblacional
- La fuga de datos es la falla más común y costosa
- Las particiones honestas respetan estructura (grupo, tiempo, espacio)
- Los modelos simples ganan más veces de lo que se reconoce
- Documentación = gobernanza

Módulo 2: árboles, bosques y boosting

¿Preguntas?

-  Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley.
-  Buelens, B., Burger, J., & van den Brakel, J. (2014). Predictive inference for non-probability samples. *Statistics Netherlands DP*.
-  Elbers, C., Lanjouw, J.O., & Lanjouw, P. (2003). Micro-level estimation of poverty and inequality. *Econometrica* 71(1).
-  Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for GLMs via coordinate descent. *JSS* 33(1).
-  Gebru, T. et al. (2021). Datasheets for datasets. *CACM* 64(12).
-  Gneiting, T., & Raftery, A.E. (2007). Strictly proper scoring rules. *JASA* 102(477).

-  Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
-  James, G. et al. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.
-  Jean, N. et al. (2016). Combining satellite imagery and ML to predict poverty. *Science* 353(6301).
-  Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in ML-based science. *Patterns* 4(9).
-  Kuhn, M., & Johnson, K. (2019). *Feature Engineering and Selection*. CRC Press.
-  Lumley, T. (2010). *Complex Surveys*. Wiley.

-  McBride, L., & Nichols, A. (2018). Retooling poverty targeting using ML. *WBER* 32(3).
-  Mitchell, M. et al. (2019). Model cards for model reporting. *FAT* 2019*.
-  Peng, R.D. (2011). Reproducible research in computational science. *Science* 334(6060).
-  Roberts, D.R. et al. (2017). CV strategies for data with structure. *Ecography* 40(8).
-  Saito, T., & Rehmsmeier, M. (2015). The PR plot is more informative than ROC under imbalance. *PLOS ONE* 10(3).
-  Vapnik, V. (1998). *Statistical Learning Theory*. Wiley.