

Módulo 3 — SVM, k-NN y Naive Bayes

Curso de Machine Learning para
estimación de pobreza e inequidad

Bloque teórico — Día 3

Día 3

Banco Mundial - INEC - USFQ

Agenda del bloque

1. SVM: márgenes y dual
2. Kernels
3. k-NN
4. Naive Bayes
5. Diagnóstico: curvas de aprendizaje y validación
6. Mapa comparativo
7. Q&A

La derivación del dual de SVM es la pieza más exigente del curso.

Al final el participante:

1. Deduce el dual de SVM y explica los vectores de soporte
2. Explica el truco del kernel con la condición de Mercer
3. Elige k y métrica para k -NN
4. Distingue variantes de NB y casos de uso
5. Lee curvas de aprendizaje y de validación para diagnosticar el modelo
6. Ubica cada modelo en el mapa comparativo

SVM: márgenes y dual

La idea del margen máximo

- Muchos hiperplanos separan dos clases
- Elegir el que maximiza el **margen**: el “carril más ancho”
- Más robusto a perturbaciones de los datos

Problema separable: formalización

Con $y_i \in \{-1, +1\}$ y normalización canónica $y_i(w^\top x_i + b) \geq 1$:

- Distancia entre las dos fronteras: $2/\|w\|$
- Maximizar margen $\Leftrightarrow$ minimizar $\|w\|^2$

$$\underset{w,b}{\text{mín}} \quad \frac{1}{2}\|w\|^2 \quad \text{s.a.} \quad y_i(w^\top x_i + b) \geq 1$$

Margen blando: el caso real (no separable)

Variables de holgura $\xi_i \geq 0$:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.a.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

- $C \rightarrow \infty$: caso duro $C \rightarrow 0$: tolera muchas violaciones

Pérdida hinge: una visión equivalente

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i(w^\top x_i + b))$$

- Convexa, no diferenciable en $yf = 1$
- Cero si bien clasificado con margen (zona muerta $\rightarrow$ esparsidad)

SVM = pérdida convexa (hinge) + regularización L_2 .

Derivación del dual: el plan

1. Lagrangiano con multiplicadores $\alpha_i \geq 0$, $\mu_i \geq 0$
2. Condiciones KKT de estacionariedad
3. Sustituir y eliminar variables primales w, b, ξ
4. Problema dual en α

Pieza central del módulo. Atención requerida.

$$\mathcal{L} = \frac{1}{2}\|w\|^2 + C \sum_i \xi_i - \sum_i \alpha_i \left[y_i (w^\top x_i + b) - 1 + \xi_i \right] - \sum_i \mu_i \xi_i$$

Meta: eliminar w, b, ξ usando estacionariedad para obtener un problema solo en α .

Condiciones KKT de estacionariedad

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \implies w = \sum_i \alpha_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \implies \sum_i \alpha_i y_i = 0 \qquad \frac{\partial \mathcal{L}}{\partial \xi_i} = 0 \implies 0 \leq \alpha_i \leq C$$

Sustitución: emerge el dual

En simple: al meter las condiciones KKT en el Lagrangiano, las incógnitas del modelo desaparecen y queda un problema que solo mira *pares de datos*.

Sustituyendo $w = \sum_i \alpha_i y_i x_i$ y $\sum_i \alpha_i y_i = 0$ en $\mathcal{L}$:

$$\mathcal{L}_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$$

- Las variables primales desaparecen
- Los datos aparecen **solo** como productos internos

El problema dual: forma final

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.a.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0$$

Tres observaciones cruciales:

1. Cuadrático convexo $\Rightarrow$ óptimo global (SMO, Platt 1999)
2. Esparsidad en muestras: vectores de soporte
3. Datos solo como $x_i^\top x_j \Rightarrow$ **kernel trick**

Vectores de soporte (complementariedad KKT)

De $\alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] = 0$:

$\alpha_i = 0$ Punto irrelevante, no influye en w

$0 < \alpha_i < C$ Vector de soporte **en el margen**, $\xi_i = 0$

$\alpha_i = C$ Vector de soporte **dentro del margen** o mal clasificado

La función de decisión depende SOLO de los vectores de soporte.

Kernels

En el dual los datos aparecen **solo** como $x_i^\top x_j$. Reemplazar:

$$K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle, \quad \phi : \mathcal{X} \rightarrow \mathcal{H}$$

- Linealidad en $\mathcal{H}$, no-linealidad en $\mathcal{X}$
- No es necesario computar ϕ explícitamente
- $\mathcal{H}$ puede ser **infinito-dimensional**

Condición de Mercer

K es válido $\Leftrightarrow$ la matriz $[K(x_i, x_j)]$ es **simétrica positiva semidefinida** (PSD) para cualquier conjunto finito de puntos.

Garantiza que K define un producto interno en algún $\mathcal{H}$.

Lineal $K(x, x') = x^\top x'$

Polinomial d $K(x, x') = (\gamma x^\top x' + r)^d$

RBF (gaussiano) $K(x, x') = \exp(-\gamma \|x - x'\|^2)$

Sigmoide $\tanh(\gamma x^\top x' + r)$ (no siempre PSD)

RBF es el default robusto.

Hiperparámetros: C y γ

- C alto: margen estrecho, modelo más ajustado
- γ alto: kernel local, fronteras complejas (sobreajuste)
- γ bajo: fronteras suaves (subajuste)
- Tuning conjunto en grid logarítmico; sensible al escalamiento

Limitaciones y posicionamiento de SVM

- Escalamiento **obligatorio**
- No produce probabilidades naturalmente (Platt scaling — Mód. 4)
- Costo de entrenamiento $O(n^2)$ a $O(n^3)$
- Sensible a desbalance sin pesos por clase
- Interpretabilidad baja con RBF

k-NN

- Dado x : encontrar las k obs. más cercanas
- Clasificar por voto mayoritario (regresión: promedio)
- *Lazy learning*: no hay parámetros que estimar

El método más simple, con propiedades teóricas notables.

Resultado de Cover & Hart (1967)

Para $k = 1$ y $n \rightarrow \infty$:

$$R_{1\text{-NN}} \leq 2R^*(1 - R^*) \leq 2R^*$$

donde R^* es el error de Bayes.

- Sin supuestos paramétricos
- Para $k \rightarrow \infty$, $k/n \rightarrow 0$: consistente

Euclídea (L_2) $\|x - x'\|_2$ — default; sensible a escala

Manhattan (L_1) $\sum_j |x_j - x'_j|$ — robusta a outliers

Minkowski- p generaliza L_1 , L_2 , Chebyshev

Mahalanobis adapta a Σ (correlaciones)

Gower datos mixtos numéricos + categóricos

- $k = 1$: alta varianza, captura ruido
- k grande: alto sesgo, suaviza demasiado
- Regla práctica $k \in [3, 25]$, **impar** en binaria (evita empates)
- Elegir por CV; ponderación por distancia opcional

- En alta p : todas las distancias tienden al mismo valor
- Concentración de la medida $\Rightarrow$ k-NN **degrada**
- Mitigaciones: PCA (Módulo 4), selección de variables

Beyer et al. (1999): $\frac{\text{dist}_{\text{máx}} - \text{dist}_{\text{mín}}}{\text{dist}_{\text{mín}}} \rightarrow 0$.

- Escalamiento **crítico**: una variable de escala $1000\times$ domina
- Costo predicción $O(n)$ por punto
- kd-trees / ball trees: $O(\log n)$ en baja dimensión
- Alta dim.: búsqueda aproximada (Annoy, HNSW)

- Baseline no paramétrico
- Diagnóstico de “localidad” del problema
- Si k-NN compite con RF/boosting: relaciones locales fuertes
- Nicho: recomendación, datos de bajo a moderado n

Naive Bayes

Regla de Bayes:

$$\mathbb{P}(Y = k | X) \propto \pi_k p(x | Y = k)$$

Modelar $p(x | Y = k)$ en alta dim es difícil. **Supuesto naive:**

$$p(x | Y = k) = \prod_{j=1}^p p(x_j | Y = k)$$

Independencia condicional dada la clase.

Domingos & Pazzani (1997):

- Para clasificación importa el **orden relativo**, no la magnitud
- NB da probabilidades mal calibradas pero clasifica bien
- Éxito histórico en clasificación de texto

Gaussian NB (continuas):

$$X_j \mid Y = k \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$$

Multinomial NB (conteos, texto), con suavizado de Laplace:

$$\hat{p}(x_j \mid k) = \frac{n_{jk} + \alpha}{n_k + \alpha V}$$

Bernoulli NB $X_j \in \{0, 1\}$: presencia/ausencia

Categorical NB X_j con > 2 niveles

Mixto continuas Gaussian + categóricas Categorical, sumar log-prob

Log-espacio evita underflow numérico.

- Sin suavizado: una categoría no observada $\rightarrow$ prob. = 0 $\rightarrow$ posterior = 0
- Add- α con $\alpha = 1$ estándar
- Equivale a prior Dirichlet uniforme

$$\hat{p}(x_j \mid k) = \frac{n_{jk} + \alpha}{n_k + \alpha V}$$

- Probabilidades **mal calibradas** (colapsan a 0 o 1)
- Supuesto de independencia ignora interacciones
- Solución: calibración Platt o Isotónica (Módulo 4)
- No competitivo en tabular moderno vs. árboles

Diagnóstico: curvas de aprendizaje y validación

Curva de aprendizaje: ¿me faltan datos o modelo?

En simple: grafica el desempeño a medida que crece el tamaño del conjunto de entrenamiento.

- Las dos curvas (train y validación) se grafican vs. n de entrenamiento
- **Brecha grande** train-validación → sobreajuste (alta varianza)
- **Ambas bajas y juntas** → subajuste (alto sesgo)
- Curva de validación que aún sube → **más datos ayudarían**

Curva de validación: encontrar el hiperparámetro justo

En simple: grafica el desempeño a medida que se varía *un* hiperparámetro.

- Eje x: valor del hiperparámetro (p.ej. k en k-NN, C en SVM, profundidad)
- Forma típica en **U**: subajuste a un lado, sobreajuste al otro
- El óptimo está en el mínimo del error de validación

Complementa la búsqueda de hiperparámetros (Módulo 2): *visualiza* el compromiso sesgo–varianza.

Síntesis y Q&A

Mapa comparativo de modelos

Modelo	Frontera	Calib. nat.	Esc. inv.	Costo entr.	Costo pred.	Interpret.
Logística	Lineal	Sí	No	Bajo	Bajo	Alta
Árbol	Escalonada	Aprox.	Sí	Bajo	Bajo	Alta
Random Forest	Escalonada	Aprox.	Sí	Medio	Bajo	Media
XGB/LightGBM	Escalonada	No	Sí	Alto	Bajo	Media (SHAP)
SVM (RBF)	Curva	No (Platt)	No	Alto (n^2)	Medio	Baja
k-NN	Local	Sí	No	Bajo	Alto	Media
Naive Bayes	Curva	Pobre	Depende	Bajo	Bajo	Alta

Una regla práctica de selección

1. Logística como referencia
2. RF como ganador rápido
3. Boosting con tuning si se persigue ceiling
4. SVM/kNN/NB solo en nichos específicos
5. Comparar todos en el mismo CV antes de decidir

- Tabular de encuesta: probablemente boosting gana
- Texto (codificación de actividad u ocupación): NB Multinomial competitivo
- Datos satelitales + tabular: RF o boosting
- Diagnóstico inicial: logística + RF como dueto

- **SVM**: margen máximo + dual + kernel trick
- **k-NN**: simple, no paramétrico, sensible a p y escala
- **NB**: rápido, transparente, mal calibrado
- Mapa de selección por tarea

Mañana cerramos el curso con los problemas que estos modelos dejan abiertos:

- Desbalance (común en pobreza)
- Calibración (esencial para política)
- Interpretación (SHAP, model cards)
- No supervisado (PCA, k-means)

Módulo 4: desbalance, calibración, interpretación, no supervisado

¿Preguntas?

-  Beyer, K. et al. (1999). When is “nearest neighbor” meaningful? *ICDT 1999*.
-  Bishop, C.M. (2006). *Pattern Recognition and Machine Learning*. Springer.
-  Boser, B.E., Guyon, I.M., & Vapnik, V. (1992). A training algorithm for optimal margin classifiers. *COLT 1992*.
-  Burges, C.J.C. (1998). A tutorial on support vector machines. *DMKD* 2(2).
-  Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning* 20(3).
-  Cover, T.M., & Hart, P.E. (1967). Nearest neighbor pattern classification. *IEEE-IT* 13(1).

-  Domingos, P. (2012). A few useful things to know about ML. *CACM* 55(10).
-  Domingos, P., & Pazzani, M. (1997). On the optimality of the simple Bayesian classifier. *Machine Learning* 29.
-  Hand, D.J., & Yu, K. (2001). Idiot's Bayes — not so stupid after all? *Int. Stat. Review* 69(3).
-  Hofmann, T., Schölkopf, B., & Smola, A.J. (2008). Kernel methods in ML. *Annals of Statistics* 36(3).
-  Hsu, C.-W., Chang, C.-C., & Lin, C.-J. (2003). A practical guide to SVM classification. *Tech. Report*, NTU.

-  McCallum, A., & Nigam, K. (1998). A comparison of event models for naive Bayes text classification. *AAAI Workshop*.
-  Murphy, K.P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press.
-  Platt, J. (1999). Fast training of SVMs using SMO. In *Advances in Kernel Methods*. MIT Press.
-  Schölkopf, B., & Smola, A.J. (2002). *Learning with Kernels*. MIT Press.
-  Vapnik, V. (1998). *Statistical Learning Theory*. Wiley.