

Módulo 4 — Desbalance, calibración, interpretación y aprendizaje no supervisado

Curso de Machine Learning para
estimación de pobreza e inequidad

Bloque teórico — Día 4

Día 4

Banco Mundial - INEC - USFQ

Agenda del bloque

1. Desbalance de clases
2. Calibración
3. Umbral por costos
4. Interpretación: importancia, PDP, SHAP
5. PCA
6. k-means
7. Síntesis del curso y Q&A

Al final del módulo el participante:

1. Elige entre class weights y SMOTE con criterio
2. Diagnostica y corrige mala calibración
3. Calcula el umbral óptimo por costos
4. Lee un SHAP plot
5. Aplica PCA y k-means con sus limitaciones

Desbalance de clases

- Pobreza extrema, trabajo infantil: prevalencia $\pi < 0,05$
- Exactitud 95 % clasificando **todo** como negativo $\Rightarrow$ inútil
- AUC-PR y sensibilidad más informativas (Saito & Rehmsmeier 2015)

Tres estrategias para enfrentarlo

1. **Reponderar** la pérdida (class weights) — en entrenamiento
2. **Remuestrear** (SMOTE, undersampling) — antes del entrenamiento
3. **Ajustar el umbral** (Elkan) — después del entrenamiento

No excluyentes; a menudo se combinan.

$$\mathcal{L}_w = -\frac{1}{n} \sum_i w_{y_i} [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

- Esquema estándar $w_k \propto 1/n_k$
- No altera la distribución original
- Compatible con casi cualquier modelo
- Default recomendado

En simple: en vez de copiar ejemplos de la clase rara, *inventa* nuevos puntos intermedios entre vecinos reales. Para cada x_i minoritario:

1. k-NN dentro de la clase minoritaria
2. Elegir un vecino x_j al azar
3. Generar sintético: $x_{\text{nuevo}} = x_i + \lambda(x_j - x_i)$, $\lambda \sim U(0, 1)$
4. Etiquetar minoritario

Interpolación = combinación convexa $(1 - \lambda)x_i + \lambda x_j$.

Borderline-SMOTE en la frontera con la mayoría

ADASYN adaptativo a densidad local

SMOTE-NC para datos mixtos numéricos + categóricos

SMOTE-N solo categóricas (utilidad limitada)

- Distorsiona la prevalencia $\Rightarrow$ recalibrar
- Amplifica ruido en regiones espurias
- Vectores no realistas con datos mixtos
- van den Goorbergh et al. (2022): class weights iguala o supera a SMOTE

1. Empezar con class weights
2. Si no resuelve, considerar SMOTE con cautela
3. Siempre verificar calibración después
4. Combinar con ajuste de umbral por costos

Calibración

Calibración

Un modelo está calibrado si $\mathbb{P}(Y = 1 \mid \hat{p}(X) = p) = p$ para todo p .

- Entre casos con $\hat{p} = 0,3$, una fracción 0,3 es positiva
- **Distinto** del poder discriminativo (AUC)

- Binar $\hat{p}$, graficar prevalencia empírica vs. media de $\hat{p}$
- Diagonal = calibración perfecta
- Por encima: **subconfianza** (RF)
- Por debajo: **sobreconfianza** (boosting)

$$\text{Brier} = \frac{1}{n} \sum_i (y_i - \hat{p}_i)^2 \quad \text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{prev}(B_m) - \bar{\hat{p}}(B_m)|$$

- Brier: proper scoring rule (calibración + refinamiento)
- ECE: error de calibración promedio, interpretable

Patrones típicos por modelo

Logística bien calibrada (proper scoring rule)

Random Forest conservadora (hacia 0.5)

Boosting sobreconfiada (hacia 0 y 1)

SVM solo scores (requiere Platt)

Naive Bayes pobre (colapsa)

Ajustar una logística sobre el score $s(x)$:

$$\hat{p}_{\text{cal}}(x) = \sigma(A \cdot s(x) + B)$$

- Paramétrico, 2 parámetros
- Funciona con poco data de calibración
- Ideal cuando la mala calibración es sigmoideal (SVM, boosting)

Función monótona no decreciente g tal que $\hat{p}_{\text{cal}} = g(s(x))$. **Pool Adjacent Violators:**

1. Ordenar por score
2. Detectar violaciones de monotonía
3. “Poolear” (promediar) bloques en conflicto
4. Iterar hasta función escalonada monótona

No paramétrica; requiere más data ($n > 1000$).

Platt vs. isotónica: criterios

	Platt	Isotónica
Data de calibración	Poca	Mucha ($n > 1000$)
Relación	Sigmoidal	General monótona
Modelo típico	SVM, boosting	RF, NB

Ambas requieren conjunto de calibración separado (train $\rightarrow$ calibrar $\rightarrow$ test).

Umbral por costos

El umbral default no siempre es óptimo

- $t = 0,5$ minimiza el error 0-1 solo si $c_{FP} = c_{FN}$
- En focalización: FN típicamente $\gg$ FP
- La decisión del umbral es política, no técnica

Con matriz de costos c_{ij} (predecir i , verdad j):

$$t^* = \frac{c_{01} - c_{00}}{(c_{01} - c_{00}) + (c_{10} - c_{11})}$$

Caso simple ($c_{00} = c_{11} = 0$): $t^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$.

Si FN cuesta el doble que FP: $t^* = 1/3$.

- FN = hogar pobre excluido (costo humano-político)
- FP = hogar no pobre incluido (costo presupuestal)
- Asimetría típica $c_{FN}/c_{FP} \in [2, 10] \Rightarrow t^* < 0,5$

Presentar la curva costo-umbral a los tomadores de decisión.

Interpretación

Importancia de variables (revisión)

- MDI: sesgada hacia variables con más niveles
- Permutación: más honesta, pero cara
- **Ambas globales**: no explican predicciones individuales

Tampoco dan el *signo* del efecto.

Partial Dependence Plots (PDP)

Efecto marginal promedio de X_j :

$$\text{PD}_j(v) = \mathbb{E}_{X_{-j}}[\hat{f}(v, X_{-j})] \approx \frac{1}{n} \sum_i \hat{f}(v, x_{i,-j})$$

Curva creciente: más X_j aumenta la predicción.

- PDP asume **independencia** entre X_j y X_{-j}
- Con correlación (ingreso vs. educación) evalúa combinaciones irreales
- Ejemplo: “educación = 0 con ingreso alto” (hogar inexistente)

En datos socioeconómicos (correlacionados): interpretaciones engañosas.

- Accumulated Local Effects (Apley & Zhu 2020)
- Integran efectos locales sobre la distribución **condicional**
- Evita regiones no realistas
- Estándar moderno para tabular con correlación

- Individual Conditional Expectation (Goldstein et al. 2015)
- Una curva por observación
- Promedio de las curvas ICE = PDP
- Revela **heterogeneidad** de efectos entre individuos

- Descomponer cada predicción **individual** en contribución por variable
- Origen: valor de Shapley (1953), teoría de juegos cooperativos
- Lundberg & Lee (2017) lo aplican a ML

Responde: ¿por qué ESTE hogar recibió ESTA predicción?

Valor de Shapley: definición y axiomas

En simple: reparte “el crédito” de una predicción entre las variables, como repartir de forma justa una ganancia entre jugadores de un equipo.

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Contribución marginal promediada sobre todos los órdenes de llegada.

- Axiomas: **eficiencia**, **simetría**, **dummy**, **aditividad**
- **Único** vector que los satisface

$$\hat{f}(x) = \phi_0 + \sum_{j=1}^p \phi_j(x), \quad \phi_0 = \mathbb{E}[\hat{f}(X)]$$

Cada $\phi_j(x)$ explica el desvío individual respecto al baseline (exacto).

Ejemplo

Predicción 0,78 = baseline 0,30 + 0,40 (hacinamiento) + 0,15 (educación) − 0,07 (urbano)

- Cálculo exacto general: $O(2^p)$, infeasible
- KernelSHAP: aproximación agnóstica al modelo
- **TreeSHAP** (Lundberg et al. 2018): exacto y eficiente para árboles, $O(TLD^2)$
- Default en XGBoost / LightGBM

Summary plot importancia global con dirección → doc. técnica

Force plot descomposición individual → auditoría de casos

Dependence plot SHAP de X_j vs. valor, coloreado por interacción

PCA

Combinaciones lineales ortogonales que maximizan varianza (Pearson 1901, Hotelling 1933):

$$v_1 = \arg \max_{\|v\|=1} \text{Var}(Xv)$$

Los v_k son **autovectores** de la matriz de covarianza, ordenados por λ_k .

En la práctica vía descomposición en valores singulares:

$$X = U\Sigma V^{\top}$$

- Columnas de V : **loadings** (direcciones / recetas)
- $U\Sigma$: **scores** (nuevas coordenadas de cada obs.)
- $\lambda_k = \sigma_k^2 / (n - 1)$: varianza capturada

- Scree plot: buscar el “codo”
- Varianza acumulada $\in [80\%, 95\%]$
- Kaiser: $\lambda > 1$ (datos estandarizados)
- Parallel analysis (Horn 1965): comparar con datos aleatorios

- Sensible a escala $\Rightarrow$ centrar y escalar
- Captura solo estructura lineal
- Loadings pueden ser difíciles de interpretar
- No lineales: t-SNE (2008), UMAP (2018)

PCA no es clustering: reduce dimensión, no agrupa.

1. **Wealth index** (Filmer & Pritchett 2001) — estándar DHS
2. Diagnóstico exploratorio (visualizar estratos en 2D)
3. Reducción de colinealidad pre-modelo
4. Anonimización

k-means

Minimizar la suma de cuadrados intra-cluster:

$$\mathcal{J}(\mu, c) = \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2$$

Algoritmo de Lloyd: (1) inicializar centroides; (2) asignar al más cercano; (3) recalcular centroides; (4) repetir. **Converge a óptimo local.**

- Inicialización inteligente: centroides “esparcidos”
- Primer centroide aleatorio
- Siguiente con probabilidad $\propto D(x)^2$ (distancia al más cercano)
- Garantía: aproximación $O(\log K)$ del óptimo global

Método del codo WCSS vs. K , buscar aplanamiento

Silueta (Rousseeuw 1987) cohesión vs. separación, $\in [-1, 1]$

Gap statistic (Tibshirani et al. 2001) compara con datos uniformes

- Asume clusters **esféricos** del mismo tamaño y densidad
- Sensible a outliers (media no robusta) → k-medoids
- Sensible a escala → estandarizar
- Solo numéricas → k-prototypes para mixtas (Huang 1998)

1. Segmentación territorial (regiones por perfil socioeconómico)
2. Tipologías de hogares para diseño de programas
3. Detección de patrones en registros administrativos
4. Cluster ID como feature en modelos supervisados

Síntesis del curso y Q&A

- **Módulo 1:** marco inferencial, leakage, particiones, baselines, reproducibilidad
- **Módulo 2:** árboles, RF (OOB), boosting (XGB/LightGBM)
- **Módulo 3:** SVM (dual + kernel), k-NN, Naive Bayes
- **Módulo 4:** desbalance, calibración, umbral por costos, SHAP, PCA, k-means

Tres mensajes integradores

1. El *pipeline* correcto importa más que el modelo
2. La interpretabilidad no es opcional en estadísticas oficiales
3. ML e inferencia clásica son complementarios, no rivales

¡Gracias! ¿Preguntas?

-  Apley, D.W., & Zhu, J. (2020). Visualizing the effects of predictor variables in black box models. *JRSS-B* 82(4).
-  Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *SODA 2007*.
-  Chawla, N.V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR* 16.
-  Elkan, C. (2001). The foundations of cost-sensitive learning. *IJCAI 2001*.
-  Filmer, D., & Pritchett, L.H. (2001). Estimating wealth effects without expenditure data. *Demography* 38(1).

-  Friedman, J.H. (2001). Greedy function approximation (PDP). *Annals of Statistics* 29(5).
-  Goldstein, A. et al. (2015). Peeking inside the black box: ICE plots. *JCGS* 24(1).
-  Guo, C. et al. (2017). On calibration of modern neural networks. *ICML 2017*.
-  He, H., & Garcia, E.A. (2009). Learning from imbalanced data. *IEEE TKDE* 21(9).
-  Horn, J.L. (1965). A rationale and test for the number of factors. *Psychometrika* 30.
-  Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *J. Educ. Psych.* 24.

-  Huang, Z. (1998). Extensions to the k-means algorithm for categorical values. *DMKD 2*.
-  Jolliffe, I.T. (2002). *Principal Component Analysis* (2nd ed.). Springer.
-  Lloyd, S.P. (1982). Least squares quantization in PCM. *IEEE-IT* 28(2).
-  Lundberg, S.M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 2017*.
-  Lundberg, S.M., Erion, G.G., & Lee, S.-I. (2018). Consistent individualized feature attribution for tree ensembles. *arXiv:1802.03888*.
-  Molnar, C. (2022). *Interpretable Machine Learning* (2nd ed.).

-  Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *ICML 2005*.
-  Pearson, K. (1901). On lines and planes of closest fit. *Phil. Mag.* 2(11).
-  Platt, J. (1999). Probabilistic outputs for SVMs. In *Advances in Large Margin Classifiers*. MIT Press.
-  Rousseeuw, P.J. (1987). Silhouettes. *J. Comput. Appl. Math.* 20.
-  Saito, T., & Rehmsmeier, M. (2015). The PR plot is more informative than ROC. *PLOS ONE* 10(3).
-  Shapley, L.S. (1953). A value for n -person games. *Contributions to the Theory of Games* II.

-  Tibshirani, R., Walther, G., & Hastie, T. (2001). Estimating the number of clusters via the gap statistic. *JRSS-B* 63(2).
-  van den Goorbergh, R. et al. (2022). The harm of class imbalance corrections for risk prediction. *JAMIA* 29(9).
-  Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate probability estimates. *KDD 2002*.